



## DISTRIBUIÇÕES DE PROBABILIDADE

Modelos Compartimentais em Epidemiologia e  
Inferência Bayesiana

Gustavo Libotte e Regina Almeida

10 de janeiro de 2022

# Distribuições de probabilidade discretas

## Distribuição binomial



- ▶ Essa distribuição de probabilidade descreve processos nos quais um evento pode ter apenas **um de dois resultados possíveis**.
- ▶ Os exemplos incluem jogar uma moeda, detectar algo em uma verificação de segurança ou ganhar na loteria.
- ▶ Seja  $p$  a probabilidade de um evento, o qual denominamos de “sucesso”;  $1 - p$  é a probabilidade do outro evento (“falha”).
- ▶ Se a tentativa for repetida independentemente  $n$  vezes, estamos interessados na probabilidade de obter exatamente  $r$  sucessos, que podemos rotular de  $P(r | p, n)$ .
- ▶ Suponha que as primeiras  $r$  tentativas sejam bem-sucedidas e o restante,  $n - r$ , sejam todas falhas.
- ▶ Como as tentativas são **independentes**, a probabilidade dessa sequência é apenas o produto das probabilidades,  $p^r (1 - p)^{n-r}$ .

# Distribuições de probabilidade discretas

## Distribuição binomial



- ▶ Esta é a probabilidade de apenas uma sequência particular de tentativas. O número de sequências únicas com essa probabilidade é o número de maneiras de selecionar  $r$  a partir de  $n$  (sem substituição), que é  ${}_nC_r$ .
- ▶ O número de maneiras de selecionar  $r$  objetos de um conjunto de  $n$  sem levar em conta a ordem de seleção é chamado de **número de combinações**  ${}_nC_r$ ,

$${}_nC_r = \binom{n}{r} = \frac{n!}{r!(n-r)!}$$







- ▶ O valor  ${}_nC_r$  é também chamado de **coeficiente binomial**.
- ▶ A distribuição binomial é dada por

$$P(r \mid p, n) = {}_nC_r p^r (1-p)^{n-r} = \binom{n}{r} p^r (1-p)^{n-r} = \frac{n!}{r!(n-r)!} p^r (1-p)^{n-r}$$

- ▶ Esta é a probabilidade de obter  $r$  sucessos de  $n$  tentativas se a probabilidade de um sucesso for  $p$ , onde é claro  $0 \leq r \leq n$ .

# Distribuições de probabilidade discretas

## Distribuição binomial



# Distribuições de probabilidade discretas

## Distribuição binomial



- **Exemplo:** Suponha que a probabilidade de falha de uma estrutura devido a terremotos seja estimada em  $10^{-5}$  por ano. Supondo que a vida útil do projeto da estrutura seja de 50 anos e a probabilidade de falha em cada ano permaneça constante e independente durante sua vida útil, então a probabilidade de nenhuma falha pode ser estimado usando a distribuição binomial como

$$\begin{aligned}P(\text{não haver falha em 50 anos}) &= P(0 \mid 10^{-5}, 50) \\&= \binom{50}{0} (10^{-5})^0 (1 - 10^{-5})^{50-0} = \frac{50!}{0!(50-0)!} (1 - 10^{-5})^{50} \\&\approx 0,99950\end{aligned}$$

$$\begin{aligned}P(\text{haver falha em 50 anos}) &= 1 - P(\text{não haver falha em 50 anos}) \\&= 1 - 0,99950 = 0,00050.\end{aligned}$$

# Distribuições de probabilidade discretas

## Distribuição binomial



- ▶ **Mais um exemplo:** Geralmente, em cerca de 80% dos chamados que um certo técnico em computação recebe para resolver panes nos computadores de clientes ele constata que o problema decorreu da presença de algum vírus.
- ▶ Suponha que, em um determinado dia, esse técnico vai visitar seis desses clientes cujos computadores necessitam de conserto.
- ▶ Admita também que os seis clientes não se comunicam por meio de computador (o que garante a independência da existência de vírus em cada computador). Calcule a probabilidade de que:
  - ▶ a) Pelo menos quatro entre os seis computadores estejam com vírus.
  - ▶ b) No máximo dois dentre eles estejam com vírus.
  - ▶ c) Todos os seis estejam com vírus.

# Distribuições de probabilidade discretas

## Distribuição binomial

► Considere:

► Sucesso = “o defeito no computador é devido a presença de vírus” ( $p = P(\text{sucesso}) = 0,80$ ).

►  $X$  = número de computadores com vírus entre os 6 a serem consertados.

► a) Então  $X \sim \text{Bin}(4 \mid 0,8,6)$ .

►  $P(X \geq 4) = P(X = 4) + P(X = 5) + P(X = 6) =$

$$= \binom{6}{4} 0,8^4 \times 0,2^2 + \binom{6}{5} 0,8^5 \times 0,2 + \binom{6}{6} 0,8^6 = 0,90112.$$

► Isso significa que é bem alta a probabilidade de pelo menos quatro entre os seis computadores estarem com vírus.

► b)  $P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2) =$

$$= \binom{6}{0} 0,2^6 + \binom{6}{1} 0,8 \times 0,2^5 + \binom{6}{2} 0,8^2 \times 0,2^4 = 0,01696.$$

► Este valor indica que é baixíssima a probabilidade de que no máximo dois deles estejam com vírus.

► c)  $P(X = 6) = 0,8^6 = 0,26214$ . Finalmente, não é tão pequena a probabilidade de que todos estejam com vírus.

# Distribuições de probabilidade discretas

## Distribuição de Poisson



- ▶ A distribuição binomial descreve eventos em que há um evento definido ocorrendo que tem um resultado bidirecional: é um “sucesso” ou um “fracasso”; algo acontece ou não.
- ▶ No entanto, muitos processos naturais são unilaterais, isto é, só são identificáveis por terem acontecido.
- ▶ Os exemplos são **quedas de raios** e **emissão de partículas**  $\alpha$  de uma fonte radioativa.
- ▶ Não podemos contar não-eventos porque **não podemos identificar uma sequência de eventos** onde algo deveria acontecer ou não.
- ▶ Suponha que, em média, esses eventos ocorram a uma taxa  $\lambda$ , de modo que  $\lambda$  é o **número esperado de eventos em algum intervalo de tempo**. Gostaríamos de encontrar a probabilidade de obtermos  $r$  eventos neste intervalo.



# Distribuições de probabilidade discretas

## Distribuição de Poisson



- Podemos descrever isso como o **limite de um processo binomial**. Se tomarmos a série temporal em  $n$  divisões, então no limite, conforme as divisões se tornam muito pequenas, de modo que  $n$  fica grande, podemos escrever  $p = \lambda/n$ . A distribuição binomial é

$$P(r \mid \lambda/n, n) = \frac{n!}{r!(n-r)!} \left(\frac{\lambda}{n}\right)^r \left(1 - \frac{\lambda}{n}\right)^{n-r} \quad (1)$$

- Agora levamos  $n$  para infinito para produzir um *continuum* de eventos. Como  $n \rightarrow \infty$  com  $r$  finito,

$$\frac{n!}{(n-r)!} = n(n-1)(n-2) \dots (n-r+1) \rightarrow n^r \quad (2)$$

- porque cada termo tende para  $n$  e

$$\left(1 - \frac{\lambda}{n}\right)^{n-r} \rightarrow \left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda} \quad (3)$$

---

<sup>1</sup>A Equação (3) é uma definição da **constante de Euler** ( $e$ ).

# Distribuições de probabilidade discretas

## Distribuição de Poisson



- Inserindo os termos das Eqs. (2) e (3) na Eq. (1),  $n^r$  cancela e terminamos com a **distribuição de Poisson**

$$P(r \mid \lambda) = \frac{e^{-\lambda} \lambda^r}{r!}$$




onde  $\lambda > 0$  e  $r \geq 0$ .

- Esta é a probabilidade de se obter  $r$  eventos se o número médio esperado for  $\lambda$ , ou seja,  $\mathbb{E}(r) = \lambda$ .
- Uma propriedade importante desta distribuição é que sua variância é  $\text{Var}(r) = \lambda$ , ou seja, **igual à média**.
- Além disso:

$$\begin{aligned} P(r+1 \mid \lambda) &= \frac{e^{-\lambda} \lambda^{r+1}}{(r+1)!} \\ &= \frac{e^{-\lambda} \lambda^r}{r!} \frac{\lambda}{r+1} \\ &= P(r \mid \lambda) \frac{\lambda}{r+1} \end{aligned}$$

# Distribuições de probabilidade discretas

## Distribuição de Poisson



# Distribuições de probabilidade discretas

## Distribuição de Poisson



- ▶ **Exemplo:** Admita que o número de falhas no recapeamento de um fio condutor de eletricidade obedece a uma distribuição de Poisson e que em média há duas falhas por metro.
- ▶ Qual a probabilidade de que:
  - ▶ a) em um determinado metro de fio o recapeamento apresente três falhas?
  - ▶ b) em sete metros de fio sejam encontradas no máximo 10 falhas?

### Solução:

- ▶ a) Seja  $X$  a variável aleatória que representa o número de falhas num dado metro de fio. Então  $X \sim \text{Poisson}(3 \mid 2)$ . Assim,  $P(X = 3 \mid 2) = \frac{e^{-2}2^3}{3!} = 0,1804$ .
- ▶ b) Nesse caso a unidade de longitude considerada é sete metros. Logo, para essa nova situação a taxa média por unidade é  $\lambda = 2 \times 7 = 14$ .

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ A **distribuição normal** geralmente ocorre em aplicações práticas, por conta do seu papel no *teorema central do limite*, que afirma que a soma de variáveis aleatórias de distribuição arbitrária segue assintoticamente uma distribuição normal quando o tamanho da amostra se torna suficientemente grande [1].
- ▶ A variável aleatória  $X$ , que tome todos os valores reais  $-\infty < x < \infty$ , tem uma **distribuição normal** (ou **distribuição Gaussiana**) se a sua função densidade de probabilidade for da forma

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_X} \exp\left(-\frac{1}{2}\left(\frac{x - \mu_X}{\sigma_X}\right)^2\right), \quad (4)$$

onde  $\mu_X, \sigma_X > 0$  são os parâmetros de posição e dispersão da variável aleatória.

- [1] A. F. Karr.  
*Probability*.  
Springer New York, New York, 1 edition, 1993.

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ A **função de distribuição acumulada** correspondente à distribuição normal é dada por

$$F_X(x) = \frac{1}{\sqrt{2\pi}\sigma_X} \int_{-\infty}^{\infty} \exp\left(-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2\right) dx.$$

- ▶ Calcular o **valor esperado** de uma variável aleatória  $X$  com distribuição normal significa obter o resultado de

$$\mathbb{E}[X] = \frac{1}{\sqrt{2\pi}\sigma_X} \int_{-\infty}^{\infty} x \exp\left(-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2\right) dx. \quad (5)$$

- ▶ Fazendo a transformação linear estabelecida por  $Z = (X - \mu_X) / \sigma_X$  e observando que  $dx = \sigma_X dz$ , a expressão anterior toma a forma

$$\begin{aligned} \mathbb{E}[X] &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} (\sigma_X z + \mu_X) e^{-z^2/2} dz \\ &= \sigma_X \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z e^{-z^2/2} dz + \mu_X \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-z^2/2} dz. \end{aligned}$$

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ Nessa soma de integrais, o termo da esquerda possui integrando  $g(z)$  que satisfaz a propriedade  $g(z) = -g(z)$ , isto é,  $g(z)$  é uma **função ímpar** e o cálculo da sua integral (que tem intervalos simétricos) resulta em zero.
- ▶ A segunda integral é igual a um, pois representa a área total abaixo da curva que descreve a função densidade de probabilidade, sem considerar o termo  $\mu_x$ .
- ▶ Portanto, a Eq. (5) equivale a  $\mathbb{E}[X] = \mu_x$ .
- ▶ Agora, considere

$$\mathbb{E}[X^2] = \frac{1}{\sqrt{2\pi}\sigma_x} \int_{-\infty}^{\infty} x^2 \exp\left(-\frac{1}{2}\left(\frac{x-\mu_x}{\sigma_x}\right)^2\right) dx.$$

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ Por meio da mesma transformações realizada no caso anterior, a expressão de  $\mathbb{E}[X^2]$  assume a forma

$$\begin{aligned}\mathbb{E}[X^2] &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} (\sigma_x z + \mu_x)^2 e^{-z^2/2} dz \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \sigma_x^2 z^2 e^{-z^2/2} dz + 2\mu_x \sigma_x \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} z e^{-z^2/2} dz + \mu_x^2 \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-z^2/2} dz.\end{aligned}$$

- ▶ Nesse caso, para calcular a primeira integral, é possível proceder com a técnica de **integração por partes**, por meio das escolhas de  $u = z$  e  $dv = z e^{-z^2/2} dz$ . Dessa forma, o seu resultado (**cujo desenvolvimento não será detalhado aqui**) será igual a um.
- ▶ No caso da resolução da segunda e terceira integrais desse somatório, pode-se notar que os seus resultados já foram encontrados durante a análise de  $\mathbb{E}[X]$ , realizada anteriormente.
- ▶ Utilizando os mesmos argumentos já citados, essas integrais valem zero e um, respectivamente.



# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)

- ▶ Logo,  $\mathbb{E} [X^2] = \sigma_x^2 + \mu_x^2$ .
- ▶ Recuperando a formulação da variância,

$$\text{Var} [X] = \mathbb{E} [X^2] - (\mathbb{E} [X])^2 ,$$

e comparando-a com os resultados obtidos nessa análise, é possível concluir que  $\text{Var} [X] = \mathbb{E} [X^2] - (\mathbb{E} [X])^2 = \sigma_x^2 + \mu_x^2 - \mu_x^2 = \sigma_x^2$ .



- ▶ Deste modo, **verifica-se que** os dois parâmetros,  $\mu_x$  e  $\sigma_x^2$ , que caracterizam a distribuição normal, são a **média** e a **variância** da variável aleatória  $X$ , respectivamente.

### Variável aleatória com distribuição normal

Portanto, diz-se que uma variável aleatória  $X$  tem distribuição normal, denotada como  $X \sim \mathcal{N} (\mu_x, \sigma_x^2)$ , com média  $\mu_x \in \mathbb{R}$ , tal que  $-\infty < \mu_x < \infty$ , e variância  $\sigma_x^2 \in \mathbb{R}_+^*$ , se a sua densidade de probabilidades for dada pela Eq. (4).

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ A distribuição Gaussiana pode ser **normalizada** pela transformação da variável  $Z = (X - \mu_x) / \sigma_x$ , utilizada anteriormente.
- ▶ Assumindo uma nova variável normal padrão  $Z$ , com média igual a zero e desvio-padrão igual a um, a função densidade de probabilidade da Eq. (4) assume a forma

$$\phi_z(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right). \quad (6)$$

- ▶ Naturalmente, a função de distribuição acumulada também está sujeita à transformação na variável aleatória, passando a ser representada como

$$\Phi_z(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z \exp\left(-\frac{1}{2}\theta^2\right) d\theta.$$

- ▶ Especificamente nesse caso em que  $Z \sim \mathcal{N}(0, 1)$ , é dito que  $Z$  possui **distribuição normal padrão**.

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ **Exemplo:** A carga de ruptura de cabos de aço de 8mm, usados em guinchos e produzidos por uma certa Companhia têm uma distribuição Normal com média de 2.210 kg e desvio padrão de 25 kg.
- ▶ A especificação mínima para a dita carga é de 2.180 kg.
- ▶ Cabos com carga de ruptura entre 2.130 e 2.180 kg ainda podem ser comercializados, porém a um preço menor, mas se tiverem carga de ruptura inferior a 2.130kg devem ser descartados.
  - ▶ Qual a percentagem de cabos que satisfazem a especificação?
  - ▶ Qual a percentagem de cabos que, mesmo não satisfazendo a especificação, poderiam ser vendidos?
  - ▶ Qual a percentagem de cabos que deveriam ser descartados?

# Distribuições de probabilidade contínuas

## Distribuição normal (Gaussiana)



- ▶ Seja  $X$  a variável aleatória que representa a carga de ruptura, em kg, dos cabos de aço. Então,  $X \sim \mathcal{N}(2210, 25^2)$ .
- ▶ a) Os cabos satisfarão a especificação se  $X > 2180$ .

$$P(X > 2180) = 1 - \Phi\left(\frac{2180 - 2210}{25}\right) = 1 - \Phi(-1, 2) = 0,8849$$

- ▶ Aproximadamente 88,5% dos cabos produzidos satisfazem as especificações.

- ▶ b)

$$\begin{aligned} P(2130 < X < 2180) &= \Phi\left(\frac{2180 - 2210}{25}\right) - \Phi\left(\frac{2130 - 2210}{25}\right) = \Phi(-1, 2) - \Phi(-3, 2) \\ &= \Phi(3, 2) - \Phi(1, 2) = 0,9993 - 0,8849 = 0,1144. \end{aligned}$$

- ▶ Aproximadamente 11,4% dos cabos podem ser vendidos a um preço inferior.
- ▶ c)  $P(X < 2130) = \Phi\left(\frac{2130 - 2210}{25}\right) = \Phi(-3, 2) = 1 - \Phi(3, 2) = 1 - 0,9993 = 0,0007$
- ▶ Portanto, deveriam ser descartados aproximadamente 0,07% dos cabos produzidos.

# Outras distribuições de probabilidade

## Distribuição Gama



- Dizemos que  $X$  tem uma distribuição **gama** com parâmetros  $\alpha$  e  $\beta$  e escrevemos  $X \sim Ga(\alpha, \beta)$ , se  $X$  tem função de densidade

$$p(x | \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} \exp(-\beta x), \quad x > 0$$

para valores  $\alpha, \beta > 0$ . Aqui,  $\Gamma(z)$  é a função gama, definida para  $z > 0$  por


$$\begin{aligned}\Gamma(z) &= \int_0^\infty t^{z-1} \exp(-t) dt \\ &= (z-1)!\end{aligned}$$

- O parâmetro  $\alpha$  é referido como o parâmetro de **forma** e  $\beta$  como o parâmetro de **escala**.
- A **média** e a **variância** de uma distribuição gama são  $\alpha/\beta$  e  $\alpha/\beta^2$ , respectivamente.


# Outras distribuições de probabilidade

## Distribuição Gama

Função densidade de probabilidade



Função de distribuição acumulada



# Outras distribuições de probabilidade

## Distribuição Beta



- Dizemos que  $X$  tem uma distribuição **beta** com parâmetros  $a, b > 0$  e escrevemos  $X \sim Be(a, b)$ , se  $X$  tem função de densidade

$$p(x | a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}$$

para  $0 < x < 1$ .

- A **média** e a **variância** da distribuição beta são, respectivamente,

$$\mu = \frac{a}{a+b} \qquad \sigma^2 = \frac{ab}{(a+b)^2(a+b+1)} = \frac{\mu(1-\mu)}{\theta+1}$$



onde  $\theta = a + b$ .

- A **distribuição uniforme** em  $[0, 1]$  é um membro da família beta, quando  $a = 1$  e  $b = 1$ .



# Outras distribuições de probabilidade

## Distribuição Beta



# Outras distribuições de probabilidade

## Distribuição Binomial negativa




- ▶ Notamos que a distribuição de Poisson é frequentemente escolhida como ponto de partida para a análise de dados de **contagem**.
- ▶ A distribuição de Poisson é limitada pelo fato de que se  $X \sim P(\lambda)$ , então  $\mathbb{E}(X) = \text{Var}(X)$ .
- ▶ Os dados de contagem são normalmente superdispersos em relação à distribuição de Poisson: **sua variância é maior do que sua média**.
- ▶ Uma **solução** é modelar a média  $\lambda$  da distribuição de Poisson como uma **variável aleatória**.
- ▶ A função de distribuição **binomial negativa** é dada por

$$\Pr(X = k) = \frac{\Gamma(k + \alpha)}{k! \Gamma(\alpha)} \left( \frac{\beta}{1 + \beta} \right)^\alpha \left( \frac{1}{1 + \beta} \right)^k \quad \text{para } k = 0, 1, \dots$$


- ▶ A distribuição binomial negativa tem média e variância, respectivamente, iguais a

$$\mathbb{E}(X) = \alpha / \beta \qquad \text{Var}(X) = \frac{\alpha(1 + \beta)}{\beta^2}$$

# Mais distribuições de probabilidade



- [1] W. A. Link and R. J. Barker.  
*Bayesian Inference: with ecological applications*.  
Academic Press, London, 1 edition, 2010.



- [1] C. A. L. Bailer-Jones.  
*Practical Bayesian Inference: a Primer for Physical Scientists*.  
Cambridge University Press, Cambridge, 1 edition, 2017.

- ▶ Seja  $X$  uma variável aleatória com distribuição **normal**. Assuma que os parâmetros desta distribuição são desconhecidos.
- ▶ Em um determinado evento aleatório, obteve-se as seguintes amostras de  $X$ :

$i$	0	1	2	3	4	5	6	7	8
$x_i$	-2.0000	-1.5000	-1.0000	-0.5000	0	0.5000	1.0000	1.5000	2.0000
$f_X(x_i)$	0.0663	0.1093	0.1613	0.2130	0.2516	0.2660	0.2516	0.2130	0.1613

- ▶ Como podemos descobrir quais os parâmetros (média e desvio-padrão) da distribuição normal que melhor **aproximam** estes valores?
- ▶ Seja  $y \sim \mathcal{N}(\mu, \sigma^2)$ , para  $0 \leq \mu \leq 10$  e  $1 \leq \sigma \leq 10$ , onde  $y_i = y(x_i)$ . Obtenha  $y^* \sim \mathcal{N}(\mu^*, \sigma^{*2})$  tal que  $(\mu^*, \sigma^{*2}) = \operatorname{argmin}_{\mu, \sigma} \sum_{i=0}^8 (y_i - f_X(x_i))^2$ .