

INTRODUÇÃO A CADEIAS DE MARKOV E MCMC

Modelos Compartimentais em Epidemiologia e
Inferência Bayesiana

Gustavo Libotte e Regina Almeida

21 de janeiro de 2022

Noções básicas sobre cadeias de Markov



- ▶ Um **processo estocástico** é qualquer coleção de variáveis aleatórias definidas sobre o mesmo espaço de probabilidade, $\{U(t), t \in T\}$, onde T é um subconjunto de \mathbb{R} que, por comodidade, é entendido como uma classe de instantes de tempo.
- ▶ Quando esta classe é o conjunto discreto de inteiros positivos $T = \{0, 1, 2, \dots\}$, o processo estocástico dito a **tempo discreto** é usualmente denotado por $\{U_n, n \geq 0\}$, sendo esta a situação típica no contexto de um esquema de simulação estocástica.
- ▶ O conjunto \mathcal{U} de valores das variáveis é denominado espaço de estados.
- ▶ Num processo o conhecimento de estados do passado e do presente influencia geralmente a plausibilidade de ocorrência dos estados futuros.
- ▶ Quando fixado o estado do presente os estados do passado deixam de ter influência no futuro, diz-se que o processo goza da propriedade de dependência de Markov.

Noções básicas sobre cadeias de Markov



- ▶ O processo $\{U_n, n \geq 0\}$ satisfazendo tal propriedade de independência condicional é denominado **cadeia de Markov**, podendo ser definido através de

$$U_{n+1} \perp\!\!\!\perp (U_0, \dots, U_{n-1}) \mid U_n \Leftrightarrow$$

$$P(U_{n+1} \in A \mid U_0 = u_0, \dots, U_n = u) = P(U_{n+1} \in A \mid U_n = u) \equiv P_n(u, A),$$

para todo evento A e $n \geq 0$, onde o símbolo $P_n(u, A)$ denota a chamada função de transição (em um passo) quando parte do instante n .

- ▶ Equivalentemente, tomando $A =]-\infty, v]$ a cadeia de Markov pode ser definida através das funções de distribuição condicionais por

$$F_{U_{n+1}}(v \mid U_0 = u_0, \dots, U_n = u) = F_{U_{n+1}}(v \mid U_n = u) \equiv F_n(u, v),$$


para todo o $v, u \in \mathcal{U}$.

- ▶ Quando a função de transição é invariável com n , sendo então denotada por $P(u, A)$ (ou $F(u, v)$), a cadeia de Markov diz-se **homogênea**.

Noções básicas sobre cadeias de Markov

- Quando o espaço de estados é um conjunto discreto, a cadeia de Markov (implicitamente homogênea) fica definida através das funções de probabilidade condicionais $P(u, \{v\})$,

$$P(U_{n+1} = v | U_0 = u_0, \dots, U_n = u) = P(U_{n+1} = v | U_n = u) \equiv p(u, v), \forall n \geq 0, u, v \in \mathcal{U}.$$



- A função de transição $p(\cdot, \cdot)$ é apresentável na forma de uma matriz P de probabilidades no caso de um número finito de estados.
- **Exemplo:** dados os estados $\{1 = \text{alta}, 2 = \text{baixa}, 3 = \text{estagnado}\}$, a matriz de transição para este exemplo é

$$P = \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}$$

Noções básicas sobre cadeias de Markov



- ▶ Restringindo-nos a uma cadeia de Markov com espaço de estados discreto, tem-se

$$P(U_{n+1} = v) = \sum_u P(U_n = u) p(u, v) = \sum_u P(U_0 = u) p^n(u, v)$$

onde $p^n(u, v) = P(U_n = v \mid U_0 = u) = \sum_z p^{n-1}(u, z)p(z, v)$, $n \geq 1$ traduz a função de transição em n passos.

- ▶ A construção de uma cadeia de Markov é assim completamente determinada pela sua função de transição, **desde que se conheça a distribuição inicial**.
- ▶ O estudo do **comportamento assintótico** ($n \rightarrow \infty$) das cadeias é fundamental para os métodos MCMC e nele desempenha um papel crucial o seguinte conceito.
- ▶ Diz-se que uma distribuição de probabilidade $\pi(u)$, $u \in \mathcal{U}$ é **estacionária** se

$$\pi(v) = \sum_u \pi(u)p(u, v)$$

- ▶ Em particular, a distribuição inicial $P(U_0 = u) = \pi(u)$ é estacionária, se e somente se, a distribuição de U_n é invariante com n , i.e. $P(U_n = u) = \pi(u)$, $\forall n \geq 0$.

Noções básicas sobre cadeias de Markov



- ▶ A ideia de estacionariedade traduz a **invariância distribucional** da cadeia no sentido de que, uma vez atingido um estado caracterizado pela distribuição marginal π , os estados seguintes da cadeia **não envolvem qualquer alteração** a π .
- ▶ Em outras palavras, é como se a cadeia atingisse uma **situação de equilíbrio** em termos de estabilidade distribucional.
- ▶ **Exemplo:** A distribuição por estados pode ser escrito como um vetor de linha estocástico x , com $x^{(n+1)} = x^{(n)}P$. Assim, se no tempo n o sistema está no estado $x^{(n)}$, e em seguida, três períodos de tempo mais tarde, no tempo $n + 3$ a distribuição é

$$\begin{aligned}x^{(n+3)} &= x^{(n+2)}P = \left(x^{(n+1)}P\right)P \\&= x^{(n+1)}P^2 = \left(x^{(n)}P\right)P^2 \\&= x^{(n)}P^3\end{aligned}$$

Noções básicas sobre cadeias de Markov

- Em particular, se num momento n o sistema está no estado 2 (baixa), então no tempo $n + 3$, a distribuição é

$$\begin{aligned}x^{(n+3)} &= [\begin{array}{ccc} 0 & 1 & 0 \end{array}] \begin{bmatrix} 0,9 & 0,075 & 0,025 \\ 0,15 & 0,8 & 0,05 \\ 0,25 & 0,25 & 0,5 \end{bmatrix}^3 \\&= [\begin{array}{ccc} 0 & 1 & 0 \end{array}] \begin{bmatrix} 0,7745 & 0,17875 & 0,04675 \\ 0,3575 & 0,56825 & 0,07425 \\ 0,4675 & 0,37125 & 0,16125 \end{bmatrix} \\&= [\begin{array}{ccc} 0,3575 & 0,56825 & 0,07425 \end{array}],\end{aligned}$$

- Utilizando a matriz de transição, é possível calcular, por exemplo, a fração de **longo prazo** de semanas durante o qual o mercado é estagnado, ou o número médio de semanas que será necessário para passar de uma estagnada a um mercado de touro.

$$\lim_{N \rightarrow \infty} P^N = \begin{bmatrix} 0,625 & 0,3125 & 0,0625 \\ 0,625 & 0,3125 & 0,0625 \\ 0,625 & 0,3125 & 0,0625 \end{bmatrix}$$

Noções básicas sobre cadeias de Markov



- ▶ A **existência e unicidade** de distribuições estacionárias depende da cadeia possuir algumas propriedades de estabilidade conhecidas como irredutibilidade e recorrência.
- ▶ Uma cadeia é **irredutível** quando pode atingir qualquer estado quando parte dele ou de outro estado qualquer em um número finito de transições.
- ▶ Diz-se **recorrente** se volta infinitas vezes ao estado de onde parte com probabilidade 1, qualquer que ele seja.
- ▶ Como caso particular, diz-se **recorrente positiva** se é finito o valor médio do tempo de retorno a u , $T_u = \min \{n \geq 1 : U_n = u\}$ quando parte dele, $\forall u$.
- ▶ Note-se que a irredutibilidade implica recorrência positiva se \mathcal{U} é finito.
- ▶ Toda a cadeia de Markov (com \mathcal{U} discreto) irredutível e recorrente positiva apresenta uma **distribuição estacionária única**.
- ▶ Por outro lado, existindo uma distribuição estacionária $\pi(v)$ tal que $\lim_{n \rightarrow \infty} p^n(u, v) = \pi(v)$, então a distribuição estacionária é **única** satisfazendo $\lim_{n \rightarrow \infty} P(U_n = v) = \pi(v)$.
- ▶ Sendo assim, independentemente da distribuição inicial, para valores suficientemente grandes de n a distribuição de U_n é aproximadamente dada por π .

Noções básicas sobre cadeias de Markov



- ▶ A convergência para a distribuição estacionária π **não é garantida** por uma cadeia irredutível e recorrente positiva.
- ▶ Todavia, se for imposto a essa cadeia a condição adicional de ser **aperiódica**, traduzida por

$$\min \{n \geq 1 : p^n(u, u) > 0\} = 1$$

basta exigir que $\exists u, p(u, u) > 0$, tal cadeia denominada então **ergódica** apresenta o comportamento limite

$$p^n(u, v) \xrightarrow{n \rightarrow \infty} \pi(v), \forall u, v \in \mathcal{U}$$

assegurando assim a convergência de $P(U_n = u)$ para $\pi(u), \forall u$.

Noções básicas sobre cadeias de Markov

Propriedade de irredutibilidade





Ilustração da propriedade de **irredutibilidade**. A cadeia da esquerda **não** é irredutível: de 3 ou 4 não podemos chegar a 1 ou 2. A cadeia da direita (uma aresta foi adicionada) **é** irredutível: cada estado pode ser alcançado a partir de qualquer outro estado.

Noções básicas sobre cadeias de Markov

Propriedade de periodicidade





Ilustração da propriedade de **periodicidade**. A cadeia à esquerda é **2-periódica**: ao sair de qualquer estado, sempre leva um múltiplo de 2 passos para voltar a ele. A cadeia à direita é **3-periódica**.

Noções básicas sobre cadeias de Markov

Propriedade de recorrência





Ilustração da propriedade de **recorrência/transitoriedade**. A cadeia da esquerda é tal que: 1, 2 e 3 são **transitórios** (ao sair desses pontos não podemos ter certeza absoluta de que voltaremos a eles) e 3-periódicos enquanto 4 e 5 são **recorrentes** (ao sair destes pontos estamos absolutamente certos de que voltaremos a eles em algum momento) e 2-periódicos. A corrente à direita tem mais uma aresta que torna a corrente completa recorrente e aperiódica.

O amostrador de Gibbs

- ▶ A construção da cadeia de Markov que se pretende que converja para a distribuição $\pi(u), u = (u_1, u_2, \dots, u_k) \in \mathcal{U}$ é no algoritmo de Gibbs feita sequencialmente por amostragem das distribuições condicionais (tipicamente univariadas) dado todos os outros componentes.
- ▶ O algoritmo vai sucessivamente substituindo num ciclo de k passos os elementos do vetor corrente u de modo que no passo j **apenas** u_j é trocado pelo valor amostrado da densidade condicional $\pi(v_j | \{u_i, i \notin j\}), j = 1, 2, \dots, k$.
- ▶ Por exemplo, tomando $k = 3$, o ciclo de 3 passos visando substituir o valor corrente $u = (u_1, u_2, u_3)$ é representável pelo esquema

$$(u_1, u_2, u_3) \xrightarrow{it.1} (v_1, u_2, u_3) \xrightarrow{it.2} (u_1, v_2, u_3) \xrightarrow{it.3} (u_1, u_2, v_3)$$

- ▶ Como cada etapa percorre os parâmetros e os atualiza de acordo com os valores atuais de todos os outros parâmetros, as amostras **não são independentes**.
- ▶ Toda a amostragem é realizada condicionalmente ao valor da iteração anterior e, portanto, as amostras formam uma **cadeia de Markov**.

O amostrador de Gibbs

Descrição formal

- ▶ A amostragem de Gibbs é projetada para **distribuições *a posteriori* multivariadas**.
- ▶ Seja $U = (U_1, U_2, \dots, U_k)$ o vetor aleatório com densidade $\pi(u)$ e denote-se por U_{-j} o vetor U sem o j -ésimo componente, $U_{-j} = (U_1, \dots, U_{j-1}, U_{j+1}, \dots, U_k)$, $j = 1, 2, \dots, k$.
 1. Dado $u^{(t)} = (u_1^{(t)}, \dots, u_k^{(t)})$, iniciado em $t = 0$, amostre cada um dos componentes, $v_j^{(t)}$, do próximo vetor da cadeia a partir da distribuição $V_j^{(t)} \sim \pi(v_j^{(t)} | u_{-j}^{(t)})$, para $j = 1, 2, \dots, k$.
 2. Finalizado o ciclo de k iterações, tome $u^{(t+1)} = (v_1^{(t)}, \dots, v_k^{(t)})$ e repita-se o ciclo 1, substituindo t por $t + 1$.
- ▶ Todo se passa como se no j -ésimo passo Gibbs do ciclo assente em $u^{(t)}$, para todo o j , se obtivesse um vetor $v^{(t)} = (u_1^{(t)}, \dots, u_{j-1}^{(t)}, v_j^{(t)}, u_{j+1}^{(t)}, \dots, u_k^{(t)})$ tal que

$$V^{(t)} | u^{(t)} \sim q_j(v^{(t)} | u^{(t)}) = \begin{cases} \pi(v_j^{(t)} | u_{-j}^{(t)}), & \text{se } v_j^{(t)} = u_j^{(t)} \\ 0, & \text{caso contrário} \end{cases}$$

O amostrador de Gibbs

Exemplo

- ▶ Para este exemplo, considere uma distribuição normal bivariada.
- ▶ A distribuição normal bivariada para X e Y , e a distribuição normal multivariada para X_1, \dots, X_m , são **generalizações** da distribuição normal para dimensões superiores.
- ▶ A distribuição normal **bivariada** é especificada por cinco parâmetros: $\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho$. Essas são as médias e variâncias de X e Y , e suas correlações.
- ▶ Se $\mu_X = \mu_Y = 0$ e $\sigma_X^2 = \sigma_Y^2 = 1$, temos a distribuição normal padrão bivariada com densidade conjunta

$$f(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right)$$

para $-\infty < x, y < \infty$ e $-1 < \rho < 1$.

- ▶ As distribuições marginais e condicionais de uma distribuição normal bivariada são normais.
- ▶ Em particular, a distribuição condicional de X dado $Y = y$ é normal com **média** ρy e **variância** $1 - \rho^2$. Da mesma forma, a distribuição condicional de Y dado $X = x$ é normal com **média** ρx e **variância** $1 - \rho^2$.

O amostrador de Gibbs

Exemplo



- ▶ O amostrador de Gibbs é implementado para simular (X, Y) a partir de uma distribuição normal padrão bivariada com correlação ρ .

$$(X, Y) \sim \mathcal{N} \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$$

- ▶ Em cada etapa do algoritmo, um componente de um vetor de dois elementos é atualizado por amostragem de sua distribuição condicional, dado o outro componente.

$$p(X, Y = y) \sim \mathcal{N} \left(\rho y, 1 - \rho^2 \right)$$

$$p(Y, X = x) \sim \mathcal{N} \left(\rho x, 1 - \rho^2 \right)$$

O amostrador de Gibbs

Exemplo












- ▶ Para este caso particular, o amostrador de Gibbs procede da seguinte forma:
 1. Inicialize $k = 0$ e $(x_k, y_k) = (0, 0)$.
 2. Gere x_k da distribuição condicional de X , dado $Y = y_{k-1}$, isto é, compute uma amostra da distribuição normal com média ρy_{k-1} e variância $1 - \rho^2$.
 3. Gere y_k da distribuição condicional de Y , dado $X = x_k$, isto é, compute uma amostra da distribuição normal com média ρx_k e variância $1 - \rho^2$.
 4. Faça $k = k + 1$.
 5. Retorne ao passo 2.

Atividade prática

Reproduza os resultados mostrados nos próximos *slides*, empregando o amostrador de Gibbs para o problema apresentado. Implemente o algoritmo mostrado acima, para algum $-1 \leq \rho \leq 1$. Use quantidade suficiente de amostras.










O amostrador de Gibbs

Exemplo




O amostrador de Gibbs

Exemplo




O amostrador de Gibbs

Exemplo




$$\rho = -0,9$$




$$\rho = 0,9$$

O amostrador de Gibbs

Exemplo



$$\rho = 0,99$$



$$\rho = 0$$

O Algoritmo de Metropolis



- ▶ Vamos considerar uma situação genérica onde temos um modelo de amostragem $Y \sim p(y | \theta)$ e uma distribuição *a priori* $p(\theta)$.
- ▶ Embora na maioria dos problemas $p(y | \theta)$ e $p(\theta)$ possam ser calculados para quaisquer valores de y e θ ,

$$p(\theta | y) = \frac{p(\theta)p(y | \theta)}{\int p(\theta)p(y | \theta) d\theta}$$

geralmente é difícil de calcular **devido à integral no denominador**.

- ▶ Se pudéssemos obter uma amostra de $p(\theta | y)$, poderíamos gerar $\theta^{(1)}, \dots, \theta^{(S)}$ $\stackrel{i.i.d.}{\sim} p(\theta | y)$ e obter aproximações de Monte Carlo para quantidades *a posteriori*, com

$$\text{E}[g(\theta) | y] \approx \frac{1}{S} \sum_{s=1}^S g(\theta^{(s)})$$

- ▶ **Mas e se não pudermos amostrar diretamente de $p(\theta | y)$?**

O Algoritmo de Metropolis



- ▶ Em termos da aproximação da distribuição *a posteriori*, o crítico não é que tenhamos amostras i.i.d. de $p(\theta | y)$.
- ▶ Mas ao invés disso, somos capazes de construir uma grande coleção de θ -valores, $\{\theta^{(1)}, \dots, \theta^{(S)}\}$, cuja distribuição empírica se aproxima de $p(\theta | y)$.
- ▶ A grosso modo, para quaisquer dois valores diferentes θ_a e θ_b , precisamos

$$\frac{\#\{\theta^{(s)} \text{ 's na coleção} = \theta_a\}}{\#\{\theta^{(s)} \text{ 's na coleção} = \theta_b\}} \approx \frac{p(\theta_a | y)}{p(\theta_b | y)}$$

- ▶ Vamos pensar **intuitivamente** sobre como podemos construir essa coleção.
- ▶ Suponha que temos uma coleção $\{\theta^{(1)}, \dots, \theta^{(s)}\}$ à qual gostaríamos de adicionar um novo valor $\theta^{(s+1)}$.
- ▶ Vamos considerar a adição de um valor θ^* que está próximo a $\theta^{(s)}$.

O Algoritmo de Metropolis



- ▶ Devemos incluir θ^* no conjunto ou não?
- ▶ Se $p(\theta^* | y) > p(\theta^{(s)} | y)$ então queremos mais que θ^* esteja no conjunto do que $\theta^{(s)}$. θ^* é **mais verossímil** do que $\theta^{(s)}$.
- ▶ Visto que $\theta^{(s)}$ já está no conjunto, então parece que **devemos** incluir θ^* também.
- ▶ Por outro lado, se $p(\theta^* | y) < p(\theta^{(s)} | y)$ então parece que **não devemos necessariamente** incluir θ^* .
- ▶ Portanto, talvez nossa decisão de incluir θ^* ou não deva ser baseada em uma comparação de $p(\theta^* | y)$ com $p(\theta^{(s)} | y)$.
- ▶ Felizmente, essa comparação **pode ser feita** mesmo que não possamos calcular $p(\theta | y)$:

$$r = \frac{p(\theta^* | y)}{p(\theta^{(s)} | y)} = \frac{p(y | \theta^*) p(\theta^*)}{p(y | \theta^{(s)}) p(\theta^{(s)})} \frac{p(y)}{p(y | \theta^{(s)}) p(\theta^{(s)})} = \frac{p(y | \theta^*) p(\theta^*)}{p(y | \theta^{(s)}) p(\theta^{(s)})}$$

O Algoritmo de Metropolis



- ▶ Tendo calculado r , como devemos **proceder**?
- ▶ Se $r > 1$:
 - ▶ **Intuição:** Como $\theta^{(s)}$ já está em nosso conjunto, devemos incluir θ^* , pois tem uma probabilidade maior do que $\theta^{(s)}$.
 - ▶ **Procedimento:** Aceite θ^* em nosso conjunto, ou seja, defina $\theta^{(s+1)} = \theta^*$.
- ▶ Se $r < 1$:
 - ▶ **Intuição:** A frequência relativa de θ -valores em nosso conjunto igual a θ^* em comparação com aqueles iguais a $\theta^{(s)}$ deve ser $p(\theta^* | y) / p(\theta^{(s)} | y) = r$. Isso significa que para cada instância de $\theta^{(s)}$, devemos ter apenas uma “fração” de uma instância de um valor θ^* .
 - ▶ **Procedimento:** Defina $\theta^{(s+1)}$ igual a θ^* ou $\theta^{(s)}$, com probabilidade r e $1 - r$ respectivamente.
- ▶ Esta é a intuição básica por trás do famoso **algoritmo de Metropolis**.

O Algoritmo de Metropolis

- ▶ O algoritmo de Metropolis procede amostrando um valor de proposta θ^* próximo ao valor atual $\theta^{(s)}$ usando uma **distribuição simétrica de proposta** $J(\theta^* | \theta^{(s)})$.
- ▶ **Simétrico** aqui significa que $J(\theta_b | \theta_a) = J(\theta_a | \theta_b)$, ou seja, a probabilidade de propondo $\theta^* = \theta_b$ dado que $\theta^{(s)} = \theta_a$ é igual à probabilidade de propor $\theta^* = \theta_a$ dado que $\theta^{(s)} = \theta_b$.
- ▶ Normalmente $J(\theta^* | \theta^{(s)})$ é muito simples, com amostras de $J(\theta^* | \theta^{(s)})$ estando perto de $\theta^{(s)}$ com alta probabilidade.
- ▶ **Exemplos:**
 - ▶ $J(\theta^* | \theta^{(s)}) = \text{Uniforme}(\theta^{(s)} - \delta, \theta^{(s)} + \delta)$
 - ▶ $J(\theta^* | \theta^{(s)}) = \text{Normal}(\theta^{(s)}, \delta^2)$
- ▶ O valor do parâmetro δ é geralmente escolhido para fazer o algoritmo de aproximação funcionar de forma **eficiente**.
- ▶ **Como δ afeta a eficiência?**

O Algoritmo de Metropolis

Resumo



- ▶ Tendo obtido um valor de proposta θ^* , nós o adicionamos ou uma cópia de $\theta^{(s)}$ ao nosso conjunto, dependendo da proporção $r = p(\theta^* | y) / p(\theta^{(s)} | y)$.
- ▶ Especificamente, dado $\theta^{(s)}$, o algoritmo de Metropolis gera um valor $\theta^{(s+1)}$ como segue:

1. Gere uma amostra $\theta^* \sim J(\theta | \theta^{(s)})$.

2. Calcule a taxa de aceitação:

$$r = \frac{p(\theta^* | y)}{p(\theta^{(s)} | y)} = \frac{p(y | \theta^*) p(\theta^*)}{p(y | \theta^{(s)}) p(\theta^{(s)})}$$

3. Tome

$$\theta^{(s+1)} = \begin{cases} \theta^*, & \text{com probabilidade } \min(r, 1) \\ \theta^{(s)}, & \text{com probabilidade } 1 - \min(r, 1) \end{cases}$$

- ▶ A etapa 3 pode ser realizada amostrando $u \sim \text{Uniforme}(0, 1)$ e definindo $\theta^{(s+1)} = \theta^*$ se $u < r$, ou definindo $\theta^{(s+1)} = \theta^{(s)}$ caso contrário.

O Algoritmo de Metropolis

Exemplo prático



- ▶ A NFL tem 32 times e cada time joga 16 jogos da temporada regular por ano, para um total de $N = 256$ jogos.
- ▶ De acordo com o site Frontline, houve $Y_1 = 171$ concussões em 2012, $Y_2 = 152$ concussões em 2013, $Y_3 = 123$ concussões em 2014 e $Y_4 = 199$ concussões em 2015.
- ▶ O número de concussões é modelado por $Y_i \sim \text{Poisson}(N\lambda_i)$, onde $\lambda_i = \exp(\beta_1 + i\beta_2)$ é a taxa no ano i .
- ▶ Para completar o modelo Bayesiano, $\beta_1, \beta_2 \sim \text{Normal}(0, \tau^2)$.
- ▶ O logaritmo da taxa média de concussão é linear no tempo, com β_2 determinando a inclinação. O **objetivo** é determinar se a taxa de concussão está aumentando, ou seja, $\beta_2 > 0$.

Atividade prática

Reproduza os resultados do próximo *slide*, usando as informações apresentadas aqui. Este problema é apresentado em [1], mas **você deve tentar implementar primeiro!**

[1] S. K. Ghosh and B. J. Reich.



Bayesian statistical methods.

Chapman & Hall/CRC, Boca Raton, 1 edition, 2019.

O Algoritmo de Metropolis

Exemplo prático

Distribuição *a posteriori* e traço de β_1, β_2 .



Os *boxplots* são a distribuição *a posteriori* de $N\lambda_i = N \exp(\beta_1 + i\beta_2)$, e os pontos são as amostras observadas.

