

# Trabalho 1

## Modelos Compartimentais em Epidemiologia e Inferência Bayesiana

18 de janeiro de 2022

### Contexto

Sabe-se que o número de indivíduos infectados em função do tempo no estágio inicial de uma epidemia segue um comportamento exponencial crescente. Seja  $t$  o tempo (em dias) e  $I(t)$  a média móvel do número diário de novos casos. Os dados mostrados na Fig. 1 retratam os 40 primeiros dias da epidemia em determinada localidade, desde que o primeiro caso foi diagnosticado.




Figura 1: Média móvel do número diário de novos casos para os 40 primeiros dias da epidemia.

### Modelagem matemática

Considere o teorema de Bayes, dado por

$$p(\theta | y) = \frac{p(y | \theta) p(\theta)}{p(y)}, \quad (1)$$

onde  $\theta$  e  $y$  denotam os vetores de parâmetros e de dados, respectivamente. Por sua vez, o modelo capaz de descrever o comportamento dos dados disponíveis é dado por

$$\mathcal{M}_\theta(t) = I(t_1) \exp(\theta_1 t) .$$

Queremos conhecer os valores de  $\theta$  em que a saída do modelo  $\mathcal{M}_\theta$  melhor represente o comportamento dos dados  $y_1 = I(t_1), y_2 = I(t_2), \dots$ . Para isso, precisamos inferir os valores de  $\theta$ , isto é, obter uma aproximação de  $p(\theta | y)$  na Eq. (1).

Assuma que a função de verossimilhança é uma distribuição normal expressa por

$$p(y | \theta) = \mathcal{N}(\mathcal{M}_\theta, \sigma^2) .$$

Neste caso, o vetor de parâmetros na inferência Bayesiana é dado por  $\theta = (\theta_1, \sigma^2)$ . Note que, como não conhecemos a variância da função de verossimilhança,  $\sigma^2$  é um hiperparâmetro do modelo, que também deve ser inferido. Assumiremos as seguintes distribuições *a priori*:

$$p(\theta_1) = \mathcal{U}(0, 1, 0, 2) \text{ dia}^{-1}$$
$$p(\sigma) = \mathcal{U}(10, 15) \text{ indivíduos}^2,$$

onde  $\mathcal{U}(a, b) = 1/(b - a)$  representa a distribuição uniforme.

## Tarefa

Use um método de amostragem da sua preferência para aproximar a probabilidade *a posteriori* conjunta  $p(\theta | y)$ , onde  $\theta = (\theta_1, \sigma^2)$  e  $y = (I(t_1), I(t_2), \dots)$ . Você deve obter as distribuições *a posteriori* marginais de cada parâmetro, assim como inferir o valor mais provável de cada distribuição aproximada. Mostre que o valor mais provável de cada parâmetro, quando usado para avaliar o modelo exponencial, fornece o melhor ajuste de  $I(t)$  no intervalo em que os dados foram disponibilizados. Além disso, considere os seguintes aspectos na sua análise numérica:

- Como a variação dos parâmetros do método de amostragem adotado afetam a convergência e o custo computacional?
- Seria possível adotar outra distribuição *a priori* para algum dos parâmetros? Como isso afetaria o procedimento de inferência?
- O diagnóstico das cadeias nos leva a crer que houve convergência?
- Qual é o nível de correlação entre os parâmetros e como isso eventualmente afetou a aproximação das distribuições?

## Regras

- O trabalho é composto por (1) código-fonte, (2) relatório e (3) apresentação.
- O relatório deve ser elaborado em formato de artigo, com *template* livre e sem limite de páginas.
- O código-fonte pode ser implementado em qualquer linguagem de programação.
- Não é permitido o uso de bibliotecas que contenham implementações do método de amostragem adotado.
- Qualquer método de amostragem pode ser empregado, desde que devidamente descrito no relatório, incluindo as referências utilizadas.
- O relatório pode ser redigido em português ou inglês.
- Os trabalhos serão em dupla.
- As apresentações terão duração máxima de 12 minutos, com mais 3–5 minutos para perguntas.
- A nota final será definida por média aritmética simples entre código-fonte, relatório e apresentação. Cada aluno da dupla receberá a mesma nota.

Prazo para envio dos relatórios e código-fonte: 28 de janeiro de 2022.

Data das apresentações: 31 de janeiro de 2022.